

PROYECTO FINAL: ECOSISTEMA DE AUTOMATIZACIÓN IA AUTÓNOMO

Triage Inteligente de Soporte y Generación de Respuestas de Datos con HITL

Diseño de Arquitectura: Ingeniero de Flujos IA

Base de Datos: Airtable (Dynamic Memory & RAG)

Orquestador Principal: n8n (Docker-based Environment)

Modelos LLM: OpenAI (GPT-4o) / Anthropic (Claude 3.5)

1. Definición del Caso de Uso e Infraestructura

El proyecto aborda la problemática común de la gestión ineficiente del soporte al cliente en empresas de servicios tecnológicos o financieros. El ecosistema desarrollado, titulado **"Triage Inteligente de Soporte e IA-RAG"**, captura correos entrantes con dudas operativas o reclamos, los clasifica según urgencia y temática utilizando un LLM, recupera fragmentos clave de directrices internas (RAG) para armar una respuesta personalizada, e inserta una fase crítica de control humano antes del envío final.

El sistema se compone de las siguientes tecnologías integradas de manera nativa:

- **Orquestador:** n8n encargado del control de estados, triggers, enrutamientos y manejo estructurado de datos.
- **Base de Datos de Control y Memoria RAG:** Airtable como repositorio de tickets, base de conocimiento atómica y logs de error.
- **Motor de Procesamiento IA:** OpenAI GPT-4o parametrizado con prompts dinámicos orientados a rol, JSON Schema estructurado y límites estrictos de tokens.
- **Canales de Comunicación Integrados:** Gmail (recepción del ticket y despacho final de la respuesta) y Slack (canal de notificaciones y control HITL).


2. Estructura de la Base de Datos (Airtable Schema)

Se diseñó una arquitectura de base de datos relacional orientada a estados y fragmentación atómica para optimizar la inyección de contexto RAG y prevenir redundancia o datos aislados:

Tabla	Campo	Tipo de Dato	Propósito y Lógica Técnica
t_tickets_soporte (Gestión de Casos)	ID_Ticket	Autonumérico / Key	Identificador de seguimiento único del incidente.
	Remitente_Email	Email	Dirección de correo de origen del cliente.
	Mensaje_Original	Texto Largo	Cuerpo del correo capturado dinámicamente por el Trigger.
	Estado_Ticket	Single Select	Estados: Pendiente , Procesando_IA , Pendiente_HITL , R Error .
	Borrador_Respuesta	Texto Largo	Respuesta técnica formulada por el LLM tras la recuperación RAG
	Aprobado_HITL	Checkbox (Booleano)	Semáforo lógico controlado por el auditor humano en Slack / Airta
t_base_conocimiento (RAG Atómico)	ID_FAQ	Autonumérico / Key	Clave primaria del fragmento de conocimiento.
	Categoria_Tema	Single Select	Etiqueta temática: Facturación, Técnico, Cuentas, Reclamaciones.
	Solucion_Validada	Texto Largo	Información atómica y verificada que el LLM usará obligatoriamente

3. Arquitectura del Flujo e Interrupción Humana (HITL)

Para asegurar que el flujo no actúe de manera descontrolada (Efecto Metralleta), se insertó una estructura de control humano en el ciclo de vida del mensaje. El diagrama inferior describe la arquitectura del workflow implementado en n8n:



4. Resiliencia, Manejo de Errores y Validación Técnica

Para lograr la calificación de arquitectura limpia y robusta frente a escenarios imprevistos (Camino Infeliz), se incorporaron los siguientes esquemas de estabilidad:

Estrategia de Error Handling (Resiliencia): Todos los nodos críticos de integración API (OpenAI y Gmail) cuentan con una ruta alternativa de fallo conectada a un nodo de error global. Si el token de OpenAI expira o se supera el límite de tasa de la API (Rate Limit), el sistema activa el nodo secundario **Airtable - Log Error**, actualiza el ticket con **Estado = "Error"** y despacha una alerta roja de alta prioridad al canal de Slack del equipo de infraestructura con el log del sistema, impidiendo que el flujo colapse de manera silenciosa.

Pruebas de Estrés y Controles de Seguridad Ejecutados

- **Filtros de Prevención de Bucles:** Se configuró una condición estricta en el nodo inicial que descarta correos que provengan del propio dominio de soporte de la empresa o que contengan etiquetas de "Auto-Reply", eliminando la posibilidad de bucles infinitos de procesamiento.
- **Consistencia en Tipo de Datos:** Los filtros de enrutamiento evalúan de forma estricta los formatos, validando booleanos nativos (`true/false`) y strings tipificados en lugar de depender de texto plano variable.
- **Optimización de Costos y Prompting:** El nodo de OpenAI utiliza un límite máximo de `max_tokens = 450` y temperatura baja (0.2) para asegurar respuestas precisas, deterministas y con un gasto computacional controlado.

5. Conclusión y Estándares de Entrega

El ecosistema desarrollado cumple de extremo a extremo con las directrices profesionales del curso. Logra reducir los tiempos de primera respuesta a incidencias de soporte técnico de un promedio de 4 horas a tan solo ****1 minuto de supervisión humana****, garantizando consistencia, eliminando errores de redacción gracias al RAG, y manteniendo un control absoluto del canal de comunicación a través del punto de interrupción HITL.